

Limites des langages algébriques

1

Tout est algébrique?

- On connaît bien les langages algébriques
 - Plusieurs façons de les caractériser
 - Les opérations qui préservent l'algébricité
 - Union, concaténation et étoile
- Tout langage est-il algébrique ?
 - Comme pour les rationnels, il existe des langages non algébriques.
 - Pour le prouver, on utilise un argument de diagonalisation.

2

Hypothèse: tout est algébrique

- algébriques = reconnaissables; en bijection avec AP et \mathbb{N} .
- On énumère les AP sur un alphabet à une lettre et on les ordonne dans une liste; L_0 est reconnu par le 1^{er} AP de la liste, L_1 par 2^e...
- Si M était dans T , il existerait un indice j tel que $M=L_j$. Puisque $M=L_j$, si
 - $j \in L_j$ alors, par définition de M , $j \notin M$
 - $j \notin L_j$ alors, par définition de M , $j \in M$
- Une contradiction dans les deux cas

	L_0	L_1	L_2	L_3
mot ₀	O	N	N	O
mot ₁	N	N	O	N
mot ₂	O	N	O	O

$T[i,j] = \text{Oui si } i \in L_j$
Non sinon
 $i \in M \Leftrightarrow i \notin L_i$
 M n'est pas dans T

L'ensemble des algébriques est infini mais dénombrable

3



Question

- Comment montrer qu'un langage L donné n'est pas algébrique.
- Problème
 - Donnée : L un langage
 - Question : L est-il non algébrique?
- Pour les rationnels, on a utilisé le principe des tiroirs sur les états parcourus pour montrer qu'on passe plusieurs fois par le même état

4

Question

- Pour les algébriques, on utilise le principe des tiroirs sur l'arbre syntaxique qui doit contenir plusieurs fois le même sous-arbre car les variables sont en nombre fini.



5

Lemme de la pompe

Lemme : Soit L un langage algébrique. Il existe une constante n (qui ne dépend que de L) telle que si $z \in L$, $|z| \geq n$, z se factorise en $z=uvwxy$ tel que

- $|vx| > 0$ et
- $|vwx| \leq n$ et
- $\forall i \geq 0, uv^iwx^iy \in L$

6

Utilisation du Lemme de la pompe

- Comme pour les rationnels, ce lemme ne sert qu'à montrer la **non algébricité** d'un langage.
- On utilise la contraposée, en supposant L algébrique et on cherche une contradiction
- Si, pour un $w \in L$ quelconque de longueur suffisante \forall décomposition $w=uvwx$ vérifiant
 - $|vx| > 0$ et
 - $|vwx| \leq n$ alors
 - $\exists i \geq 0, uv^iwx^iy \notin L$

On conclut que L n'est pas algébrique

7

Exemple $L = \{a^i b^j c^i : i > 0\}$

- On suppose L algébrique et on fixe n .
- Soit $z = a^n b^n c^n = uvwx$
- $|vwx| \leq n \Rightarrow vx$ ne peut avoir à la fois des a et c
 - v et x ne contiennent que des $a \Rightarrow uwy$ manque de a
 - v et x ne contiennent que des $b \Rightarrow uwy$ manque de b
 - v et x ne contiennent que des $c \Rightarrow uwy$ manque de b
 - vx contient des a et $b \Rightarrow uwy$ manque de a et de b
 - vx contient des b et $c \Rightarrow uwy$ manque de b et de c
- Pour chaque factorisation, on aboutit à une contradiction (le mot uwy n'est pas dans le langage). On en déduit donc que L n'est pas algébrique.

8

Autre exemple : $L = \{a^i b^j c^i d^j : i, j \geq 1\}$

- On suppose L algébrique; soit n la constante du lemme
- On choisit $z = a^n b^n c^n d^n$
 - $|vx| > 0$ et
 - $|vwx| \leq n$ et
 - $\exists i \geq 0, uv^iwx^iy \notin L$
- Par la condition 2, vx contient soit
 - Qu'une seule lettre a ou b ou c ou d
 uwy n'est pas dans le langage, car cette lettre manque
 - Que des a et des b
 - Que des b et des c
 - Que des c et des d

cas analogues

 uwy n'est pas dans le langage, car deux lettres manquent

9

Mais...

- Ca ne marche pas à tous les coups! Exemple de $L = \{a^i b^j c^k d^l : i=0 \text{ ou } j=k=l\}$
 Qui n'est pas algébrique mais, en choisissant $z = b^i c^k d^l$ ou $z = a^i b^j c^i d^j$ et en factorisant $z = uvwx$, on peut toujours trouver une décomposition pour laquelle $uv^iwx^iy \in L$ (c.a.d. vwx ne contient que des b ou que des a)
- Le lemme n'est pas utilisable avec un langage de cette forme
- Comment faire?

10

Lemme d'Ogden

- Il faut une version plus forte du lemme de la pompe.
- C'est le lemme d'Ogden qui permet de marquer des positions et d'ajouter à v et x des conditions sur le marquage
- Lemme** : Soit L un langage algébrique. Il existe une constante n qui ne dépend que de L telle que $\forall z \in L$ avec au moins n lettres marquées, z se factorise en $z=uvwx$ tel que
 - v et x ont ensemble au moins une position marquée et
 - vwx a au plus n positions marquées et
 - $\forall i \geq 0, uv^iwx^iy \in L$

11

Exemple $L = \{a^i b^j c^k : i \neq j, j \neq k \text{ et } k \neq i\}$

- On suppose L algébrique; soit n la constante du lemme d'Ogden
- On choisit le mot $z = a^n b^{n+1} c^{n+2n!}$ avec les a marqués
 - vx a au moins une position marquée et
 - vwx a au plus n positions marquées et
 - $\exists i \geq 0, uv^iwx^iy \in L$
- Cas 1 : v (ou x) a deux symboles distincts (a et b). Pour $i=2$, $uv^iwx^iy \notin L$ car on a $(ab)(ab)$

12

Exemple $L = \{a^i b^j c^k : i \neq j, j \neq k \text{ et } k \neq i\}$

- v ou x doit contenir des a . (condition 1).
- Si $x \in b^*$ ou c^* , $v \in a^+$; si $x \in a^+$, $v \in a^*$
- Cas 2 : $x \in b^*$ et $v = a^p$ $0 < p < n+1$ donc p divise $n!$
 - Soit q t.q. $pq = n!$

$$z' = uv^{2q+1}wx^{2q+1}y \text{ doit \^etre dans } L$$
 - mais $v^{2q+1} = a^{2pq+p} = a^{2n!+p}$.
 - Comme $|uwy|_a = (n-p)$, $|z'|_a = 2n!+n$
 - Ni v ni x ne contiennent de c , donc $|z'|_c = |z|_c = n+2n!$
 - Mais dans ce cas, $|z'|_a \neq |z'|_c$, une contradiction
- Les autres cas sont traités de la même manière

13

Propriétés de clôture

14

L'union

Lemme : Les langages algébriques sont clos pour l'union

- Soient $G_1 = (N_1, T_1, S_1, R_1)$ et $G_2 = (N_2, T_2, S_2, R_2)$ qui engendrent resp. L_1 et L_2
- On construit G_3 qui engendre $L_1 \cup L_2$.
 $G_3 = (N_1 \cup N_2 \cup \{S_3\}, T_1 \cup T_2, S_3, R_1 \cup R_2 \cup \{S_3 \rightarrow S_1 \mid S_2\})$
- Pour que tout marche bien, il faut ajouter comme hypothèse que $N_1 \cap N_2 = \emptyset$ et que $\{S_3\} \not\subseteq N_1 \cup N_2$
- On ajoute la règle $S_3 \rightarrow S_1 \mid S_2$
 - Par la dérivation $S_3 \rightarrow S_1$, on engendre L_1
 - Par la dérivation $S_3 \rightarrow S_2$, on engendre L_2

15

Exemple

$$L = \{a^i b^j : i, j \geq 0, i = j \text{ ou } i > j\}$$

- On découpe L en deux langages:

$$L_1 = \{a^i b^j : i, j \geq 0, i = j\}$$

$$L_2 = \{a^i b^j : i, j \geq 0, i > j\}$$

Dont on va faire l'union : $S_1 \rightarrow a S_1 b \mid \varepsilon$

$$S_2 \rightarrow a S_2 b \mid a \mid a S_2$$

On ajoute : $S_3 \rightarrow S_1 \mid S_2$ pour obtenir l'union

16

Preuve

- On montre $L_1 \cup L_2 = L(G_3)$
- $L_1 \cup L_2 \subseteq L(G_3)$
 - $w \in L_1$, la dérivation $S_3 \rightarrow S_1 \rightarrow^* w$ est une dérivation de G_3 puisque toute règle de G_1 est aussi une règle de G_3 .
 - $w \in L_2$, la dérivation $S_3 \rightarrow S_2 \rightarrow^* w$ est une dérivation de G_3
- $L(G_3) \subseteq L_1 \cup L_2$
 - Soit $w \in L(G_3)$. Alors la dérivation $S_3 \rightarrow^* w$ commence soit par $S_3 \rightarrow S_1 \rightarrow^* w$ soit par $S_3 \rightarrow S_2 \rightarrow^* w$
 - Dans le premier cas, seules des variables de G_1 peuvent apparaître car $N_1 \cap N_2 = \emptyset$ et seules les règles de G_1 sont utilisées. L'autre cas est pareil.

17

La concaténation

Lemme : Les langages algébriques sont clos pour la concaténation

- $G_1 = (N_1, T_1, S_1, R_1)$ et $G_2 = (N_2, T_2, S_2, R_2)$ engendrent respectivement L_1 et L_2
- On construit G_4 qui engendre $L_1.L_2$
 $G_4 = (N_1 \cup N_2 \cup \{S_4\}, T_1 \cup T_2, S_4, R_1 \cup R_2 \cup \{S_4 \rightarrow S_1 S_2\})$
- Pour que tout marche, il faut l'hypothèse $N_1 \cap N_2 = \emptyset$ et $\{S_4\} \not\subseteq N_1 \cup N_2$
- En ajoutant la règle $S_4 \rightarrow S_1 S_2$
 - à partir de S_1 (resp S_2), on engendre L_1 (resp L_2)

18

Exemple

$$L = \{a^i b^j c^k : i, j, k \geq 0, i = j\}$$

- On découpe L en deux langages:

$$L_1 = \{a^i b^j : i, j \geq 0, i = j\}$$

$$L_2 = \{c^k : k \geq 0\}$$

Dont on va faire la concaténation

$$S_1 \rightarrow a S_1 b \mid \varepsilon$$

$$S_2 \rightarrow c S_2 \mid \varepsilon$$

On ajoute la règle $S_4 \rightarrow S_1 S_2$ pour la concaténation

19

Étoile de Kleene

Lemme : Les langages algébriques sont clos pour l'étoile de Kleene

- $G_1 = (N_1, T_1, S_1, R_1)$ engendre L_1

- On construit G_5 qui engendre $(L_1)^*$

$$G_5 = (N_1 \cup \{S_5\}, T_1, S_5, R_1 \cup \{S_5 \rightarrow \varepsilon \mid S_1 S_5\})$$

Pour que tout marche, il faut l'hypothèse $\{S_5\} \notin N_1$

- En ajoutant la règle $S_5 \rightarrow \varepsilon \mid S_1 S_5$

- Par la dérivation $S_5 \rightarrow S_1$, on engendre L_1

- Par la dérivation $S_5 \rightarrow S_5$, on peut recommencer

- On engendre donc bien l'étoile de Kleene

20

Exemple

$$L = \{(a^n b^n)^k : k, n \geq 0\} = (a^n b^n)^*$$

- Soit

$$G_1 = (N_1, T_1, S_1, \{S_1 \rightarrow \varepsilon \mid a S_1 b\})$$

- Qui engendre $L_1 = \{a^n b^n : n \geq 0\}$

- Par la règle $S_5 \rightarrow \varepsilon \mid S_1 S_5$ on engendre $(L_1)^*$

21

Théorème

Les langages algébriques sont clos

- Pour l'union

- Pour la concaténation

- Pour l'étoile de Kleene

- Cela nous donne une manière de construire une grammaire algébrique en « découpant » astucieusement le langage à engendrer

22

$$L = \{a^i b^j c^k : i, j, k \geq 0, i = j \text{ ou } j = k\}$$

- Se décompose comme

$$\{a^i b^j c^k : i, j, k \geq 0, i = j\} \cup \{a^i b^j c^k : i, j, k \geq 0, j = k\}$$

- $\{a^i b^j c^k : i, j, k \geq 0, i = j\} = \{a^i b^j : i, j \geq 0, i = j\} \cdot \{c^k : k \geq 0\}$

- $\{a^i b^j : i, j \geq 0, i = j\}$ engendré par $S_1 \rightarrow \varepsilon \mid a S_1 b$

- $\{c^k : k \geq 0\}$ engendré par $S_2 \rightarrow \varepsilon \mid c S_2$ (c^*)

- Leur concaténation : $S_5 \rightarrow S_1 S_2$

- $\{a^i b^j c^k : i, j, k \geq 0, j = k\} = \{a^i : i \geq 0\} \cdot \{b^j c^k : j, k \geq 0, j = k\}$

- $\{a^i : i \geq 0\}$ engendré par $S_3 \rightarrow \varepsilon \mid a S_3$

- $\{b^j c^k : j, k \geq 0, j = k\}$ engendré par $S_4 \rightarrow \varepsilon \mid b S_4 c$

- Leur concaténation : $S_6 \rightarrow S_3 S_4$

- L'union : $S \rightarrow S_5 \mid S_6$

23

Clôture par intersection

- Si L et M sont deux langages algébriques, alors on ne peut en déduire que $L \cap M$ est algébrique

$L = \{a^i b^j c^k : i > 0\}$ n'est pas algébrique

- $L_1 = \{a^i b^j c^k : i > 0, j > 0\}$ est algébrique

- Concaténation de $L = \{a^i b^j c^k : i > 0\}$ et $M = \{c^k : k > 0\}$

- $L_2 = \{a^i b^j c^k : i > 0, j > 0\}$ est algébrique

- Concaténation de $N = \{a^i c^k : i > 0\}$ et $P = \{b^j c^k : j > 0\}$

- $L_1 \cap L_2 = L$ n'est pas algébrique

- Remarque :** On ne peut pas dire que l'intersection de deux langages algébriques n'est jamais algébrique

- Il suffit de prendre $L = M$ avec L et M algébriques pour que $L \cap M = L$ soit algébrique

24

Corollaire

- On en déduit que les langages algébriques ne sont pas clos par complémentation
- Sinon, par les lois de Morgan, on aurait

$$L_1 \cap L_2 = \overline{\overline{L_1} \cup \overline{L_2}}$$

et les algébriques seraient clos par intersection

25

Intersection avec rationnels

- Théorème:** Si L est algébrique et M rationnel, alors $L \cap M$ est algébrique
- L'idée est de faire fonctionner en parallèle un AP pour L et un AF pour M

26

Intersection avec rationnels

- Construction :**
 - On a $A = (Q_1, \Sigma, \Gamma, \delta_1, q_1, Z, F_1)$ un AP qui accepte L par EF
 - Et $B = (Q_2, \Sigma, \delta_2, q_2, F_2)$ un AF qui accepte M
 - On construit un automate à pile produit $(Q_1 \times Q_2, \Sigma, \Gamma, \delta, (q_1, q_2), Z, F_1 \times F_2)$
 - Transition normale : Si $\delta_1(q, a, X) = (q', \gamma)$ et $\delta_2(p, a) = p'$, alors
 - $\delta((q, p), a, X) = ((q', p'), \gamma)$
 - ϵ -transition : Si $\delta_1(q, \epsilon, X) = (q', \gamma)$, on ne s'intéresse pas à N:
 - $\delta((q, p), \epsilon, X) = ((q', p), \gamma)$

27

Utilité de ces propriétés

- Comme pour les langages rationnels, les propriétés de clôture sont utiles
 - Pour construire des langages algébriques
 - Pour montrer qu'un langage donné n'est pas algébrique

28

Moralité

- permet de simplifier les preuves de non-algébricité de certains langages
- Par exemple pour un langage qui conduit à une « explosion » de cas à considérer :

$$D = \{ww : w \in \{a, b\}^*\}$$
 - On suppose D algébrique
 - Soit $L = a^*b^*a^*b^*$ un langage rationnel
 - Alors, $D \cap L$ est algébrique
 - Mais $D \cap L = \{a^i b^j a^i b^j : i, j > 0\}$ réputé non algébrique (analogue à $\{a^i b^j c^i d^j : i, j > 0\}$)
 - Donc D n'est pas algébrique

29